

计算机前沿课程论文复现报告

摘要

旅行时间估计 (Estimated Time of Arrival, 简称 ETA) 是智能交通系统的关键部分, 其会被直接应用到日常的交通出行中, 并作为一些相关问题的前置任务。本次选择复现的论文是发表在 KDD2023 的解决 ETA 问题的方法 ProbtTE [1]。这是一个不确定性感知的概率旅行时间估计方法。报告中会简要介绍该方法, 并给出复现的细节和结果。

关键词: 旅行时间估计; 不确定性

1 引言

旅行时间估计 (Estimated Time of Arrival, 简称 ETA) 是移动轨迹数据挖掘中的一个基础问题。ETA 在智能交通系统 (Intelligent Transportation Systems, 简称 ITS) 中起着重要作用, 是智慧城市基础建设中不可或缺的一环。一方面, ETA 会被直接应用到日常的交通出行中, 如: (1) 使用地图软件查询出行路线时, 会有相应的时间估计来辅助用户规划好出行时间; (2) 外卖配送等相关服务会预估货物的送达时间, 给外卖员和顾客相应的反馈。另一方面, ETA 也是一些 ITS 相关问题的前置任务, 如: (1) 在路线规划问题中, 需要考虑时间因素的影响, 帮助用户更快到达目的地; (2) 在车辆调度问题中, 需要预估车辆调度的时间, 以此反映用户的等待时间。因此, 准确的旅行时间估计能够提高 ITS 的运行效率、降低应用使用者的出行成本、节约能源减少污染。

2 相关工作

2.1 旅行时间估计

近年来, 随着深度学习模型在许多任务上的广泛使用, ETA 问题的研究也开始使用深度学习技术。Wang 等人首次将 ETA 问题表述为纯回归问题, 并提出了宽线性模型、深度神经网络和递归神经网络相结合的深度学习模型, 该模型能够充分结合三类结构的优势来解决 ETA 问题 [2]。Li 等人结合残差网络提出了一个多任务表示学习框架, 通过同时学习多个任务帮助模型捕捉道路网络结构和时空知识, 进而学习到有用的特征表示 [3]。Yuan 等人将学习历史轨迹的表示作为辅助任务, 辅助 ETA 问题的学习, 此外其设计了有效的方法来生成时空特征的隐藏表示, 特别地, 该方法对于 ETA 的查询不提供路径信息, 模型只会获得起点和终点的信息 [4]。Hong 等人将道路路网图转换成一个多关系路网图, 首次将异构信息网络和图神经网络应用于 ETA 任务, 从空间和时间的角度提取异构信息, 并提出一个框架来融合这些信息以学习 ETA 任务的表示 [5]。Fang 等人提出了一个端到端的深度学习网络, 使用图

注意力机制来关注空间和时间信息的联合关系 [6]。Chen 等人提出了一种层次化自注意力网络，其设计了一个分段编码器，可以从多个视角来解释轨迹的特征，进而捕捉细粒度的时空依赖关系，此外还利用一个自适应的自注意力模块来提高性能 [7]。Yuan 等人设计了一种编码器-解码器框架，该方法通过捕捉和利用异质性、邻近性、周期性和动态性这四个方面的时空特征来提高 ETA 准确性 [8]。Fang 等人提出了一种基于元学习的框架，其将 ETA 视作是一个少样本学习问题，学习其中的元知识，从而快速适应用户的驾驶偏好 [9]。

3 本文方法

3.1 本文方法概述

图 1 所示，本文方法一共有四个主要部分，分别是：表征学习模块，联合输出模块，联合优化模块，以及软标签生成模块。下面各小节将简要介绍各个部分。值得注意的是，图中的绿色部分的回归器（Regressor）和分类器（Classifier）写反了位置，应该反过来才是正确的图示。

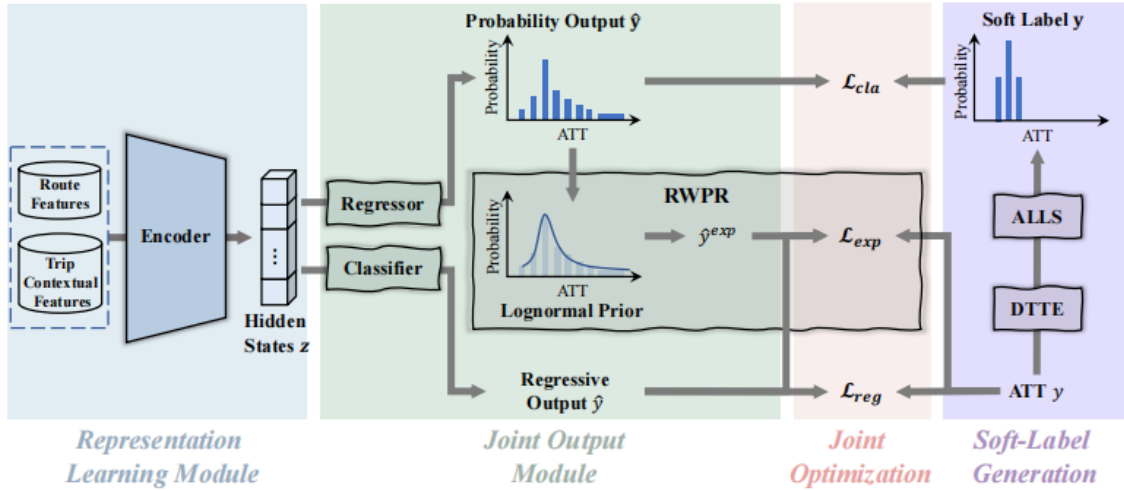


图 1. 方法示意图

3.2 表征学习模块

表征学习模块主要使用一个 Encoder 来编码路线特征和旅行的上下文信息。这里的 Encoder 使用的是文献 [2] 所提出的 WDR 模型。WDR 由 Wide, Deep, 以及 Recurrent 三部分组成。Wide 部分通过组合的方式学习不同特征值之间的关系；Deep 部分通过深度神经网络学习更有泛化性的隐特征；Recurrent 部分使用 LSTM 学习路线序列信息。在 ProbTTE 中 Recurrent 部分被更换为更先进的 Transformer。

3.3 联合输出模块

联合输出模块包括一个分类器和一个回归器。分类器用于对时间进行粗粒度的分类，回归器则是预测更精准的 ETA 估计。文中还提出了一个额外的正则化模块（Route-Wise Prior Regularization，简称 RWPR）来合并路线先验知识。

3.4 联合优化模块

联合优化模块主要是对三个 $Loss$ 的联合优化。联合优化了回归的损失 L_{cla} ，分类的损失 L_{reg} ，以及路线知识先验正则化的损失 L_{exp} 。

3.5 软标签生成模块

ProbTTE 方法使用软标签来替代我们更常使用的硬标签。硬标签是指在标签向量中，只有对应类别的维度的元素是 1，其余元素为 0 的标签。而软标签这更像一个分布，对应类别的临近元素不是 0，而被分配有一定的比例的可能性。比如，一个硬标签为 $(0, 0, 1, 0, 0, 0, 0)$ ，对应软标签为 $(0, 0.2, 0.6, 0.2, 0, 0, 0)$ 。

4 复现细节

4.1 与已有开源代码对比

原文代码没有开源。本次实验对 ProbTTE 方法进行复现，成功实现除了 RWPR 部分的剩余部分。并在此基础上，添加了对路线长度的分类的尝试，结果也取得一定的提升。

4.2 实验环境搭建

编程语言环境为 Python。本次复现的模型使用 Pytorch 深度学习框架实现。

4.3 数据集

本小节给出所使用的数据集的情况。本次实验使用的是一个来着上海的车辆轨迹数据集。数据集包含有 2015 年 4 月份的车辆轨迹数据。数据集的划分情况如表 1 所示，其中有前三周的数据作为训练集，两天的数据作为验证集，最后一周的数据作为测试集。

表 1. 车辆轨迹数据情况

	日期	轨迹数量	路段数量
训练集	2015.4.1-2015.4.21	67,738	1,083,808
验证集	2015.4.22-2015.4.23	6,788	108,608
测试集	2015.4.24-2015.4.30	23,418	374,688

数据集的轨迹距离分布情况和轨迹时间分布情况分别如图 2 和图 3 所示。可以看到其分布的长尾效应是很明显的。




图 2. 数据集轨迹距离分布




图 3. 数据集轨迹时间分布

5 实验结果分析

本次复现的实验结果如表 2 所示。可以看到尝试使用距离分布分类器的 $ProbTTE_{distance}$ 取得了最好得预测效果，在 MAPE 项比 WDR 降低了 0.43%。同样发现使用了文中的时间分布分类器和软标签，均会带来预测精度的提升，但提升没有使用距离分布分类器大。

表 2. 实验结果表

	MAPE	MAE	RMSE
WDR	17.76%	95.61	155.79
$ProbTTE_{cla}$	17.66%	94.64	154.92
$ProbTTE_{soft}$	17.63%	94.35	154.88
$ProbTTE_{distance}$	17.33%	93.41	153.48

- WDR : DIDI 改进前部署的模型，等价于 ProbTTE 的 Encoder 加回归器。
- $ProbTTE_{cla}$: 加入时间分布分类器。
- $ProbTTE_{soft}$: 将时间分布标签改为软标签。
- $ProbTTE_{distance}$: 尝试使用距离分布分类器。

6 总结与展望

本次计算机前沿技术论文复现，部分实现论文中的模型，通过实验获得了符合预期的旅行时间预测结果，能够体现出论文中的创新点所带来的性能提升。与此同时，尝试让模型学习距离的分布替代时间的分布，获得了不错的效果。

参考文献

- [1] Hao Liu, Wenzhao Jiang, Shui Liu, and Xi Chen. Uncertainty-aware probabilistic travel time prediction for on-demand ride-hailing at didi. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 4516–4526, 2023.
- [2] Zheng Wang, Kun Fu, and Jieping Ye. Learning to estimate the travel time. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 858–866, 2018.
- [3] Yaguang Li, Kun Fu, Zheng Wang, Cyrus Shahabi, Jieping Ye, and Yan Liu. Multi-task representation learning for travel time estimation. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*, pages 1695–1704, 2018.
- [4] Haitao Yuan, Guoliang Li, Zhifeng Bao, and Ling Feng. Effective travel time estimation: When historical trajectories over road networks matter. In *Proceedings of the 2020 acm sigmod international conference on management of data*, pages 2135–2149, 2020.
- [5] Huiting Hong, Yucheng Lin, Xiaoqing Yang, Zang Li, Kung Fu, Zheng Wang, Xiaohu Qie, and Jieping Ye. Heteta: Heterogeneous information network embedding for estimating time of arrival. In *Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining*, pages 2444–2454, 2020.
- [6] Xiaomin Fang, Jizhou Huang, Fan Wang, Lingke Zeng, Haijin Liang, and Haifeng Wang. Constgat: Contextual spatial-temporal graph attention network for travel time estimation at baidu maps. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2697–2705, 2020.
- [7] Zebin Chen, Xiaolin Xiao, Yue-Jiao Gong, Jun Fang, Nan Ma, Hua Chai, and Zhiguang Cao. Interpreting trajectories from multiple views: A hierarchical self-attention network for estimating the time of arrival. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 2771–2779, 2022.
- [8] Haitao Yuan, Guoliang Li, and Zhifeng Bao. Route travel time estimation on a road network revisited: Heterogeneity, proximity, periodicity and dynamicity. *Proceedings of the VLDB Endowment*, 16(3):393–405, 2022.
- [9] Xiaomin Fang, Jizhou Huang, Fan Wang, Lihang Liu, Yibo Sun, and Haifeng Wang. Ssml: Self-supervised meta-learner for en route travel time estimation at baidu maps. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining*, pages 2840–2848, 2021.